

无人机动态射频感知的物理退化建模与扩散恢复

方忠盛

西安电子科技大学

2025 年 7 月 23 日

目录

- 1 研究动机与问题演进
- 2 物理前向退化模型
- 3 求解方法：扩散后验采样
- 4 实验验证
 - 实验设置
 - 实验结果
- 5 总结与展望

目录

- 1 研究动机与问题演进
- 2 物理前向退化模型
- 3 求解方法：扩散后验采样
- 4 实验验证
 - 实验设置
 - 实验结果
- 5 总结与展望

研究动机：高保真无线电地图的价值与挑战

关键基础设施

无线电环境地图 (REM) 是赋能下一代无线技术的关键基础设施，在网络规划、频谱管理、高精度定位等领域具有核心战略价值。

现有构建方法的两大范式及其困境

范式一：正向生成

- **思路：**已知基站/环境 \rightarrow AI 模型生成。
- **代表：**RadioUNet, RME-GAN, RadioDiff。
- **挑战：**泛化能力与数据依赖。

范式二：反向重建

- **思路：**稀疏测量值 \rightarrow 插值算法恢复。
- **代表：**IDW, Kriging。
- **挑战：**物理假设失效 (二阶平稳性)，效果普遍较差。

我们的选择

我们专注于反向重建范式，旨在突破其物理假设的局限性。

问题演进：从地面静态采样到空中动态感知

传统采样方式的困境

传统的反向重建依赖于地面固定传感器的稀疏测量，存在三大根本性制约：

- **成本与部署**：部署成本高昂，灵活性差。
- **稀疏性**：难以实现高密度采样。
- **维度限制**：无法获取关键的三维空间信息。

无人机：一个更优的采样平台

模式一：静态悬停测量

- **优点**：数据质量较高。
- **缺点**：效率提升有限。

模式二：动态连续测量

- **优点**：采样效率高。
- **缺点**：引入复杂的测量退化。

我们研究的核心切入点

如何精确地建模并补偿无人机动态测量引入的退化，从而在保证高采样效率的同时，实现前所未有的地图重建保真度。

目录

- 1 研究动机与问题演进
- 2 物理前向退化模型
- 3 求解方法：扩散后验采样
- 4 实验验证
 - 实验设置
 - 实验结果
- 5 总结与展望

测量退化的统一物理模型 I：模式对比

动/静态测量的退化过程分析

对两种测量模式进行深入的物理分析，可以发现它们的退化过程遵循统一的数学框架，但具体形式不同。

模式一：静态悬停测量

其退化模型为：

$$\mathbf{y}_{static} = (\mathbf{x} * h_a) + \mathbf{n} \quad (1)$$

- 退化源于天线孔径导致的**天线模糊** (h_a) 与随机噪声 \mathbf{n} 。
- 结论**：静态测量并非“完美”，它本质上是真实信号场 \mathbf{x} 的一个模糊版本。

模式二：动态连续测量

其退化模型更为复杂：

$$\mathbf{y}_{dynamic} = ((\mathbf{x} * h_a) * h_m) \odot M + \mathbf{n} \quad (2)$$

- 在天线模糊 (h_a) 基础上，额外引入了**运动模糊** (h_m) 和**稀疏采样** (M)。
- 结论**：动态测量在保证效率的同时，引入了更严重的复合型退化。

测量退化的统一物理模型 II：核心工作

我们工作的核心：统一建模

通过对测量模式的分析，我们发现问题的关键，在于构建一个能够统一描述动态测量中所有**确定性退化**的单一数学对象——**系统点扩展函数 (System PSF)**。

我们将其定义为天线模糊核与运动模糊核的卷积：

$$\text{PSF}_{\text{sys}} = h_a * h_m \quad (3)$$

这个统一的 PSF 模型，为我们后续构建一个完整的、高保真的前向退化算子奠定了核心理论基础。

前向退化过程的物理分解

总体建模

我们构建了一个高保真的物理前向算子，将无人机动态测量的退化过程数学化地建模为三重物理效应的叠加：

$$\mathbf{y} = ((\mathbf{x} * \text{PSF}_{\text{sys}}) \odot M) + \mathbf{n} \quad (4)$$

三大物理效应

- **系统性模糊** ($*\text{PSF}_{\text{sys}}$): 由传感器物理局限性导致的点扩展函数 (PSF) 模糊，是天线模糊与运动模糊的卷积。
- **信息稀疏性** ($\odot M$): 由无人机稀疏扫描路径导致的确定性采样缺失。
- **随机噪声** ($+\mathbf{n}$): 由设备和环境引入的随机干扰。

目录

- 1 研究动机与问题演进
- 2 物理前向退化模型
- 3 求解方法：扩散后验采样**
- 4 实验验证
 - 实验设置
 - 实验结果
- 5 总结与展望

求解框架：一个病态的物理逆问题

贝叶斯求解思路

我们的目标是从退化的观测 y 中恢复 x ，这是一个典型的病态逆问题。其最优解存在于后验概率分布 $p(x|y)$ 中。根据贝叶斯定理：

$$p(x|y) \propto \underbrace{p(y|x)}_{\text{物理约束 (似然)}} \cdot \underbrace{p(x)}_{\text{数据先验}}$$

核心挑战

- ❶ 如何定义一个强大的、能代表真实无线电地图的**先验** $p(x)$ ？
- ❷ 如何设计一个高效的算法来对这个复杂的后验分布进行**采样**？

扩散模型 (DDPM) I: 核心思想与前向加噪




图: DDPM 核心思想: 一个可逆的加噪与去噪过程 (引自 Ho et al., 2020)

核心思想

DDPM 将图像生成过程, 建模为一个从纯噪声 \mathbf{x}_T 出发、逐步学习“撤销”噪声的反向去噪过程。这个过程是预先定义的、固定的前向加噪过程的逆过程。


前向过程 (Forward Process)

该过程通过 T 步, 逐渐将数据 \mathbf{x}_0 注入高斯噪声。其任意步 t 的状态可由 \mathbf{x}_0 直接算出:

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

其中 $\bar{\alpha}_t$ 是预先设定的信噪比系数。

扩散模型 (DDPM) II: 反向去噪与作为先验的角色



反向过程 (Reverse Process)

反向过程旨在学习一个由神经网络 θ 参数化的分布 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$, 来近似真实的后验分布。

- 目标分布:

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\sigma}_\theta(\mathbf{x}_t, t))$$

- 核心实现:** 训练一个 U-Net 网络 $\epsilon_\theta(\mathbf{x}_t, t)$, 来预测在时间步 t 时施加于 \mathbf{x}_0 上的总噪声 ϵ 。

DDPM 作为强大的图像先验

这个预训练好的去噪网络 ϵ_θ 包含了关于“一张图片应该是什么样的”的全部知识。

- 它能精确地近似“先验分数” $\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t)$, 即指向更像“真实图片”方向的梯度。
- 结论:** DDPM 为我们解决了贝叶斯求解的第一个挑战——提供了一个强大的、可计算的通用图像先验 $p(\mathbf{x})$ 。

扩散后验采样 (DPS) 原理

求解思路：梯度引导下的采样

有了先验分数，我们可以通过引导来求解后验分布。后验分数函数可以分解为：

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}|\mathbf{y}) = \underbrace{\nabla_{\mathbf{x}} \log p(\mathbf{x})}_{\text{“先验”引导}} + \underbrace{\nabla_{\mathbf{x}} \log p(\mathbf{y}|\mathbf{x})}_{\text{“似然”引导}} \quad (5)$$




图: DPS 去噪过程可视化

DPS 核心步骤：迭代式“预测-校正”

在 DDPM 反向去噪的每一步中，额外施加一个由“似然分数”决定的物理引导力。

- 1 预测：DDPM 从 \mathbf{x}_t 预测出初步的清晰图像 $\hat{\mathbf{x}}_0$ 。
- 2 校正：根据物理模型，计算预测值与真实观测 \mathbf{y} 的差距，并沿该差距的负梯度方向对 $\hat{\mathbf{x}}_0$ 进行修正。

目录

- 1 研究动机与问题演进
- 2 物理前向退化模型
- 3 求解方法：扩散后验采样
- 4 实验验证**
 - 实验设置
 - 实验结果
- 5 总结与展望

实验设置：一个可控的基准验证模型

核心思路

为验证我们提出的物理建模与 DPS 求解框架的潜力，我们首先构建并实现了一个**基准实验**。该实验将复杂的物理退化过程，简化为计算机视觉中标准的高斯模糊与路径修复的组合问题，并采用引导扩散 (Guided Diffusion) 框架进行求解。

退化模型 (Degradation)

根据 `task_config.yaml` 的设定：

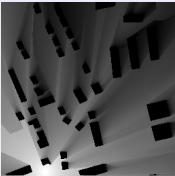

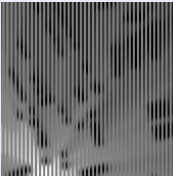
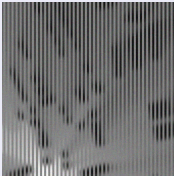
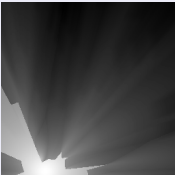
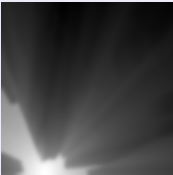
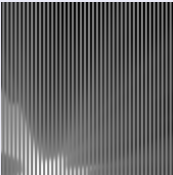
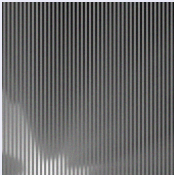
- **模糊 (Blur)**:
 - ▶ 类型：高斯模糊
 - ▶ 核尺寸：61, 强度 σ_b : 3.0
- **稀疏 (Sparsity)**:
 - ▶ 航线间距：6, 航带宽度：3
- **噪声 (Noise)**: $\sigma_n = 0.05$

求解器与数据集 (Solver & Data)

- **基础模型**: DDPM UNet
- **数据集**: 3D Radiomap
- **求解算法 (DPS)**:
 - ▶ 框架: guided-diffusion
 - ▶ 方法: 投影采样 ('ps')


退化过程解析：一个极具挑战性的逆问题

退化过程可视化 (以 10m 和 20m 高度为例)

高度	真实值 (GT)	仅模糊	仅稀疏	最终输入
10 m				
20 m				

退化过程分析与结论

图: 20m 高度下的退化输入



关键观察

- **退化严重性:**

- ▶ 我们的模型所面对的输入，是同时遭受了严重模糊和信息缺失的**复合退化**结果。

- **高度的影响:**

- ▶ 飞行高度越高，因波束展宽导致的天线模糊效应越显著，为恢复任务带来了更大的挑战。

对求解器的要求




这种极端的退化程度，对恢复算法提出了极高的要求。它不仅需要具备强大的**图像先验**来“脑补”大面积的缺失信息，还需要精确地理解并“逆转”复杂的**物理模糊**过程。

定性结果：低速模式恢复效果（低空）




低速模式 (0.5 m/s) 下，不同飞行高度的恢复效果对比

高度	真实值 (GT)	退化观测 (Input)	恢复结果 (Ours)
----	----------	--------------	-------------

5 m



10 m






定性结果：低速模式恢复效果（高空）




低速模式 (0.5 m/s) 下，不同飞行高度的恢复效果对比

高度	真实值 (GT)	退化观测 (Input)	恢复结果 (Ours)
----	----------	--------------	-------------

15 m



20 m



定量结果：方法在不同高度下的恢复指标

使用 DPS 的方法在不同高度下的恢复结果指标

飞行高度	PSNR (dB) ↑	SSIM ↑	LPIPS ↓	NMSE ↓
5 m	23.97	0.698	0.314	0.0452
10 m	24.82	0.799	0.228	0.0239
15 m	26.52	0.844	0.217	0.0119
20 m	31.90	0.926	0.219	0.0062

结果分析

- 随着飞行高度的增加，大部分恢复指标（PSNR, SSIM, NMSE）表现出显著的提升。
- 尽管高空观测的物理模糊更严重（天线足迹更大），但由于信号传播的“空中弥散”效应，高空信号场本身更平滑、结构更简单。

目录

- 1 研究动机与问题演进
- 2 物理前向退化模型
- 3 求解方法：扩散后验采样
- 4 实验验证
 - 实验设置
 - 实验结果
- 5 总结与展望

总结与展望

核心贡献

- 提出并构建了一个用于无人机动态射频感知的高保真**物理前向退化模型**，首次对天线模糊与运动模糊进行了统一建模。
- 将该物理模型与先进的**扩散后验采样 (DPS) 框架**相结合，形成了一个物理信息引导的、端到端的重建方案。
- 通过基准实验，验证了该框架在处理复杂退化逆问题上的巨大潜力。

未来工作

- **模型实现**：将完整的、基于 IMU/GPS 的动态物理算子嵌入到 DPS 框架中
- **对比实验**：用传统的空间插值法/图像去模糊方法分别进行恢复
- **算法拓展**：将更新的采样方法应用到该框架中。

谢谢聆听！

Q & A